Hochschule RheinMain
Prof. Dr. Adrian Ulges

17.04.2024

# Künstliche Intelligenz (SoSe 2024)

# Aufgabenblatt 1

**zu bearbeiten bis: 24.04.2024**

---

*Bearbeiten Sie die Implementierungsaufgaben generell in Zweier-Teams!*

**Aufgabe 1.1 (Python und Numpy)**
Wir werden im Rahmen des Praktikums ausgiebig mit Python und numpy (Pythons mächtiger Bibliothek für Numerik und lineare Algebra) entwickeln. Während die MI-ler zumindest mit Python vertraut sein sollten, haben viele AI-ler, WI-ler und ITS-ler bisher allenfalls kleine Programme geschrieben. Lesen Sie sich deshalb zur Auffrischung das sehr gute Python- und Numpy-Tutorial der Stanford University durch:

`http://cs231n.github.io/python-numpy-tutorial/`

Es reicht, bis zum Beginn des Themas "Broadcasting" reinzuschauen.

**Aufgabe 1.2 (Datenanalyse)**
Wir werden in den ersten Wochen der Veranstaltung einen **News-Classifier** implementieren, der Artikel der New York Times in ihre jeweilige Kategorie (*sports*, *politics*, ...) einsortiert. Als ersten Schritt hierzu schauen wir uns die zugehörigen Trainings- und Testdaten an:

- Laden Sie sich aus dem Read.MI die Datein `train.json` und `test.json` herunter. Wir werden unseren Klassifikator auf `train.json` trainieren, und auf `test.json` testen wie gut das gelernte Modell funktioniert. Sie können sich die JSON-Files im Browser anschauen (`firefox train.json`):

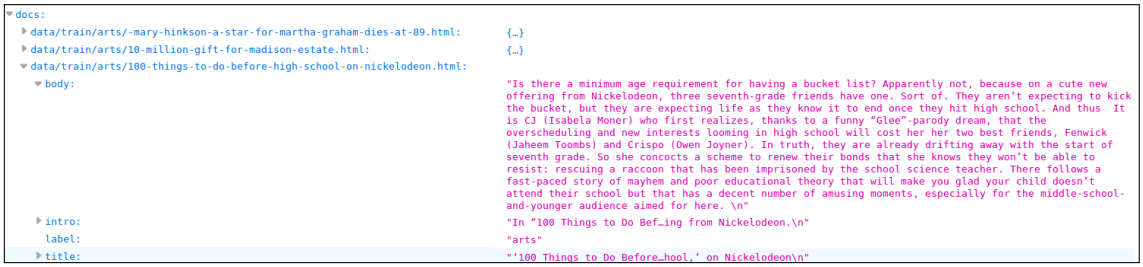


- Mit den folgenden Kommandos können Sie die Daten in Python laden:

```
import json

with open("train.json") as file:
    data = json.load(file)

print(data["docs"])
```

`data` ist nun ein geschachteltes Python-Dictionary. Hierbei enthält **data['vocabulary']** den Grundvokabular, d.h. alle Terme die in der Trainingsmenge vorkommen. Besonders häufige Terme (wie *the*) wurden gefiltert, und alle Terme wurden gestemmt, d.h. auf ihren Wortstamm reduziert (deshalb steht im Vokabular z.B. *audienc* statt *audience*).

**data['docs']** enthält die Dokumente selbst, jedes mit einem Titel, Einleitungssatz (`intro`) und Nachrichtentext (`body`). **Wichtig für Sie** sind vor allem die Felder `label` und `tokens`. `label` gibt an, zu welcher News-Kategorie ein Artikel gehört. In `tokens` finden Sie sämtliche Einzelterme, die im jeweiligen Artikel auftauchen.

- Laden Sie `train.json` und analysieren Sie mit einem kleinen Python-Skript die Daten. Schauen Sie sich das erste Dokument an (könnten Sie anhand der Tokens die Klasse erraten?).
  [Deliverable] Ermitteln Sie außerdem, welche Kategorien/Klassen es gibt.

**Aufgabe 1.3 (Naive Bayes: Implementierung 1 – Training)**
Implementieren Sie das **Training** eines Naive-Bayes-Klassifikators. Dieser soll automatisch Artikel der *New York Times* ihren Kategorien (wie *arts, technology, sports, ...*) zuordnen.

- In `classifier.py` (siehe Read.MI) finden Sie ein Programmgerüst, das `train.json` einliest und den Backbone einer Klasse `NaiveBayesDocumentClassifier` enthält.
- Sie starten das Skript mit folgendem Befehl:

  ```
  python classifier.py --train
  ```

  Sie erhalten einen `NotImplementedError`, weil die Methode `train()` noch nicht implementiert ist.
- Implementieren Sie nun `train()`:
  - Verwenden Sie – siehe Vorlesung – boolesche Bag-of-Words Features: Kommt ein Term in einem Dokument vor, ist das entsprechende Merkmal 1, ansonsten 0. Die *Häufigkeit* des Terms innerhalb des Dokuments ist irrelevant.
  - `train()` soll dementsprechend die Wahrscheinlichkeiten $P(x_i{=}1|y)$ für jeden Term $x_i$ und jede Klasse $y$ lernen, sowie den Prior $P(y)$. Diese Wahrscheinlichkeitstabellen können Sie z.B. als Dictionaries speichern:

    ```
    P['sports']['superbowl']=0.32,
    ```

    oder in Numpy-Arrays, z.B. (für die Wahrscheinlichkeit, dass das i-te Wort in einem beliebigen Dokument der j-ten Klasse auftritt):

    ```
    P[i][j]=0.32
    ```

    [Deliverable] Wahrscheinlichkeitstabellen für $P(y)$ und $P(x_i{=}1|y)$. Sammeln Sie Beispieleinträge als Plausibilitätschecks.
  - Schreiben Sie außerdem etwas Code, um den trainierten Klassifikator zu speichern und später wieder zu verwenden. Hier bietet sich z.B. das Python-Modul `pickle` an.